

MIAGE_



TRAITEMENT DISTRIBUÉ DES DONNÉES TEXTUELLES EN NLP AVEC DASK




Asma Azri, Lucas Pantanella, Souleimane El Qodsi



MIAGE_

PROBLÉMATIQUE

**COMMENT PEUT-ON CRÉER UN CORPUS
D'APPRENTISSAGE EXPLOITABLE PAR DES LLM EN
TRAITANT ET PRÉPARANT À GRANDE ÉCHELLE DES
DONNÉES TEXTUELLES BRUTES ?**



MIAGE_



SOMMAIRE

- 01 Présentation de l'outil Dask
- 02 Positionnement dans le Big Data
- 03 Architecture et fonctionnement
- 04 Avantages / Limites
- 05 Comparaison avec les concurrents
- 06 Démonstration pratique
- 07 Conclusion & ouverture




DASK – QU'EST-CE QUE C'EST ?

Un outil Python pour traiter
de grandes quantités de
données rapidement



Dask permet de :

- traiter des données très volumineuses
- exécuter des calculs en parallèle
- utiliser plusieurs cœurs ou machines



DOMAINES D'UTILISATION

Big Data

Machine
Learning

Finance

Recherche
scientifique



Dask = performance + scalabilité + simplicité



POSITIONNEMENT DANS LE BIG DATA

OUTIL : DASK

- Outil Big Data intermédiaire entre Pandas (limité) et Spark (lourd)
- Spécialiste du traitement distribué flexible sur données massives
- Idéal pour préparer des datasets à grande échelle avant l'entraînement LLM

DOMAINE : NLP

- Adapté aux corpus textuels volumineux (nettoyage, prétraitement, fusion, segmentation)
- Permet d'automatiser des pipelines NLP complexes
- Facilite la construction de datasets structurés pour modèles de langage

MÉTHODE : TRAITEMENT DISTRIBUÉ

- Exécute le nettoyage massif en parallèle sur plusieurs nœuds
- Capable de gérer des données supérieures à la RAM
- Réduit fortement le temps de préparation des corpus

SYNTHÈSE :

Dask se positionne comme la solution Python efficace pour traiter de grands volumes de textes avant l'analyse NLP



ARCHITECTURE & FONCTIONNEMENT

ARCHITECTURE DISTRIBUÉE


- Découpage du corpus en partitions de texte
- Scheduler central qui répartit et optimise les tâches
- Fonctionne sur PC, serveur ou cluster sans changer le code

MODÈLE DE CALCUL


- Exécution lazy : planification automatique avant calcul
- Parallélisation du nettoyage (tokenisation, filtrage, normalisation...)
- Support des volumes supérieurs à la RAM (“out-of-core”)

INTÉGRATION NLP


- API compatible Pandas → ingestion facile de textes bruts
- Orchestration de pipelines NLP massifs (prétraitement → structuration)
- Dashboard pour monitorer les tâches et détecter les étapes critiques



ARCHITECTURE & FONCTIONNEMENT



Avantages et limites de Dask




Comparaison avec Spark



Critère	Dask	Spark
Simplicité d'usage	★★★★★	★★★★
Volumétrie	Moyenne	Excellente
Performance	Excellente sur des datasets de petite à moyenne, sur une architecture adaptée	Meilleure sur des ensembles plus larges de données avec des architectures plus complexes
Intégrations à d'autres outils	Faible	Élevée

DÉMONSTRATION PRATIQUE



CONCLUSION & OUVERTURE



Bilan


- Dask permet un traitement massif et distribué de données textuelles.
- Les pipelines NLP deviennent scalables, automatisés et efficaces.
- Les données brutes sont transformées en corpus prêt pour les LLM.

Points clés

- Outil : Dask – flexible, puissant, basé sur Python
- Domaine : Big Data & NLP à grande échelle
- Méthode : Parallélisation + optimisation mémoire
- Objectif : Dataset propre pour entraîner des modèles LLM

Ouverture

- Intégration avec des modèles LLM (embeddings, fine-tuning)
- Passage à des clusters cloud (AWS / Azure / GCP)
- Traitement multimodal : texte + image + audio





**Merci pour votre
attention**

